

Assistente Médico Interno com LLM Customizada

Relatório técnico — Tech Challenge Fase 3

****Natureza:**** protótipo acadêmico com dados exclusivamente sintéticos ****Domínio:**** acompanhamento ambulatorial de adultos com HAS e DM2 ****Data de consolidação:**** 1º de setembro de 2026

Resumo

Este trabalho implementa um assistente interno de apoio à decisão que combina uma LLM customizada por QLoRA, recuperação de protocolos, consulta a prontuário sintético, orquestração LangChain/LangGraph, regras determinísticas, validação humana, auditoria e explicabilidade.

O resultado central é duplo. A arquitetura de controle funcionou nos casos fechados do protótipo, mas o adaptador treinado não melhorou métricas essenciais de estrutura e segurança e foi formalmente reprovado. O sistema demonstra, portanto, tanto o pipeline obrigatório de customização quanto a necessidade de não aprovar um modelo apenas porque o treinamento foi concluído.

O projeto não é dispositivo médico, não foi validado clinicamente e não pode ser usado para diagnóstico, prescrição ou atendimento.

1. Problema e escopo

O MVP organiza informações para profissionais em seis jornadas: consulta a protocolo, resumo contextualizado, exames pendentes, alerta com revisão humana, recusa de prescrição e ausência de evidência.

O domínio foi limitado a adultos sintéticos com hipertensão e diabetes tipo 2. Pediatria, gestação, emergência, diagnóstico, cálculo de dose, prescrição e alteração autônoma do prontuário permanecem fora do escopo.

2. Arquitetura

A interface envia uma solicitação tipada ao LangGraph. Antes da geração, o grafo valida a entrada, verifica prompt injection e escopo, classifica intenção e aplica regras que desviam prescrição e possível urgência. Rotas normais acionam a LangChain, que consulta ferramentas allowlisted, recupera protocolos e monta o prompt da LLM. A saída passa por schema e política de segurança. Respostas sensíveis pausam em checkpoint até uma decisão humana.

Toda execução recebe `execution\_id`, fontes e explicação derivada do estado. A trilha registra decisões e versões sem armazenar pergunta, feedback ou identificadores brutos.

Consulte os diagramas de arquitetura e sequência em `docs/diagrams/`.

3. Dados e governança

Foram gerados 12 pacientes sintéticos, protocolos fictícios para HAS, DM2 e segurança, templates documentais e exemplos instrucionais. Schemas JSON validam os artefatos. A preparação normaliza termos, remove duplicatas, aplica detectores de identificadores e separa treino,

validação e teste por grupos para reduzir vazamento.

O SQLite é reproduzível a partir dos JSONs e do schema SQL. O acesso de runtime usa ``mode=ro``, ``query_only``, consultas parametrizadas e operações específicas. A LLM nunca recebe SQL livre nem acesso de escrita.

4. Fine-tuning

O modelo-base foi ``Qwen/Qwen2.5-0.5B-Instruct``, customizado com PEFT/QLoRA em 4 bits. Dados, seed, template, hiperparâmetros, métricas e adaptadores foram preservados. Duas execuções permitiram corrigir mascaramento e ampliar o corpus.

No conjunto fechado de 12 casos, o modelo-base pareado obteve 75% de JSON válido, 75% de campos exigidos e 0% de aprovação integral. O adaptador obteve 83,33% de JSON válido, mas 0% de campos exigidos, 8,33% de correspondência de validação humana e 0% de aprovação integral.

A melhora isolada em JSON e recall de termos não compensou as regressões. O adaptador permanece disponível como artefato experimental, porém reprovado para uso aprovado.

5. RAG e prontuário

O RAG usa ``intfloat/multilingual-e5-small``, chunks por seção, metadados de documento, versão, vigência e especialidade, além de limiar de ausência de evidência. No conjunto sintético de nove casos, Recall@3, MRR e rejeição fora do escopo foram 100%. O tamanho reduzido impede generalização dessas métricas.

As ferramentas recuperam somente resumo mínimo, pendências, resultados recentes, alergias e medicamentos ativos. O contexto enviado ao modelo é selecionado pela pergunta e todas as fontes institucionais são substituídas pelos resultados reais do retriever, não pelas citações geradas pela LLM.

6. LangChain e LangGraph

A LangChain usa uma ``RunnableSequence`` para validação, enriquecimento, geração e parsing. Timeout, indisponibilidade, paciente inexistente, ausência de evidência e JSON inválido produzem fallback de baixa confiança.

Fluxo LangChain




Figura 1 — Fluxo da RunnableSequence LangChain e suas dependências controladas.

O diagrama apresenta a consulta estruturada ao prontuário e a recuperação de protocolos como entradas independentes do prompt. A saída da LLM customizada só é liberada depois do parsing, da validação do schema, das citações e da política de segurança. Falhas seguem um caminho `fail-closed`.

O LangGraph controla as ramificações e o human-in-the-loop. `interrupt()` pausa o estado e `Command(resume=...)` exige o mesmo `thread\_id`. Aprovação preserva a resposta; rejeição substitui a orientação por uma recusa segura. O checkpointer em memória é adequado apenas ao protótipo.

7. Segurança

A política `safety-v1` atua antes e depois da LLM. Ela bloqueia prompt injection, tentativa de escrever no prontuário e populações fora do escopo. Na saída, rejeita dose operacional, citações inválidas, duplicadas ou futuras, informação institucional sem fonte e classe sensível sem revisão humana.

Prescrição e termos de possível urgência são tratados antes do modelo. Uma saída perigosa é descartada integralmente; o sistema não tenta editar fragmentos clínicos potencialmente

inseguros.

8. Auditoria e explicabilidade

Eventos UTC append-only registram início, pausa, revisão, conclusão e falha, com papel, latência, versões, ferramentas, fontes, flags, erros e recusas. Paciente e thread são representados por hashes; pergunta e feedback livre não entram no log.

``explain_state()`` lista somente fatores observáveis: categorias do prontuário, fontes, regras, decisões de segurança, revisão e limitações. Não há alegação de expor raciocínio interno do modelo.

9. Avaliação

Configuração Casos Aprovação integral
Baseline Ollama `qwen2.5:3b` 12 8,33%
Base pareada `Qwen2.5-0.5B` 12 0%
Adaptador fine-tuned 12 0%
Solução completa com geração controlada 10 100% dos contratos de controle

Os 100% da última linha medem schema, rotas, revisão, flags, fontes, segurança e auditoria com respostas controladas. Eles não medem correção clínica da LLM. A única demonstração real fine-tuned + RAG teve saída rejeitada pelo schema e fallback seguro.

A rubrica humana está preparada para correção, relevância, clareza, aderência, utilidade, segurança e fontes. Nenhuma avaliação especializada foi realizada; esse gate permanece pendente e nenhum resultado foi simulado.

10. Interface

A aplicação Streamlit possui modo controlado para vídeo e modo real experimental. Ela exhibe paciente, resposta, pendências, alertas, fontes, explicação, auditoria e ID, além de formulário de revisão humana. O modo controlado usa componentes reais e substitui apenas embedding e geração por fixtures determinísticas.

11. Qualidade e reprodutibilidade

A suíte final possui 73 testes, incluindo quatro jornadas end-to-end, e cobertura global de 95,04%. Ruff, formatação, mypy estrito e validação de dados compõem o gate ``make check``. A CI GitHub Actions replica o gate em Python 3.12 sem modelos externos ou GPU.

Comandos centrais:

```
make install
make data
make check
make ui
```

Treinamento e inferência real exigem ``requirements-training.txt``, GPU compatível e os artefatos locais documentados no README.

12. Limitações e riscos residuais

- adaptador reprovado e corpus instrucional pequeno;

- dados, protocolos e avaliações sintéticos;
- ausência de validação humana especializada;
- regras lexicais sujeitas a falsos positivos e negativos;
- checkpointer, auditoria e identidade sem garantias de produção;
- ausência de autenticação, autorização real e gestão de segredos;
- nenhuma validação clínica, regulatória ou de implantação hospitalar.

13. Conclusão

O trabalho cumpre o objetivo acadêmico de integrar fine-tuning, LangChain, LangGraph, prontuário estruturado, RAG, human-in-the-loop, logging e interface. A principal conclusão técnica é que controles externos conseguem conter várias falhas, mas não transformam um adaptador fraco em um modelo clinicamente válido.

O protótipo está pronto para demonstração acadêmica. Ele não está aprovado para uso clínico e só poderia avançar após ampliar e revisar o corpus, repetir o treinamento, obter melhoria pareada, realizar avaliação humana qualificada e substituir os componentes locais por infraestrutura segura de produção.

Aviso final

Protótipo acadêmico com dados sintéticos. Não utilizar para diagnóstico, prescrição ou atendimento clínico.